MARZOUK SALMA
EL OUKILI NADA
KORCHI ISRAE

Formation AI

APPRENEZ L'IA, SOYEZ ACTEUR DU CHANGEMENT

Ceux qui comprennent l'IA aujourd'hui seront les leaders de demain.

MARZOUK SALMA
EL OUKILI NADA
KORCHI ISRAE

Rappel Python

APPRENEZ L'IA, SOYEZ ACTEUR DU CHANGEMENT

Ceux qui comprennent l'IA aujourd'hui seront les leaders de demain.

Kit de survie Python Data

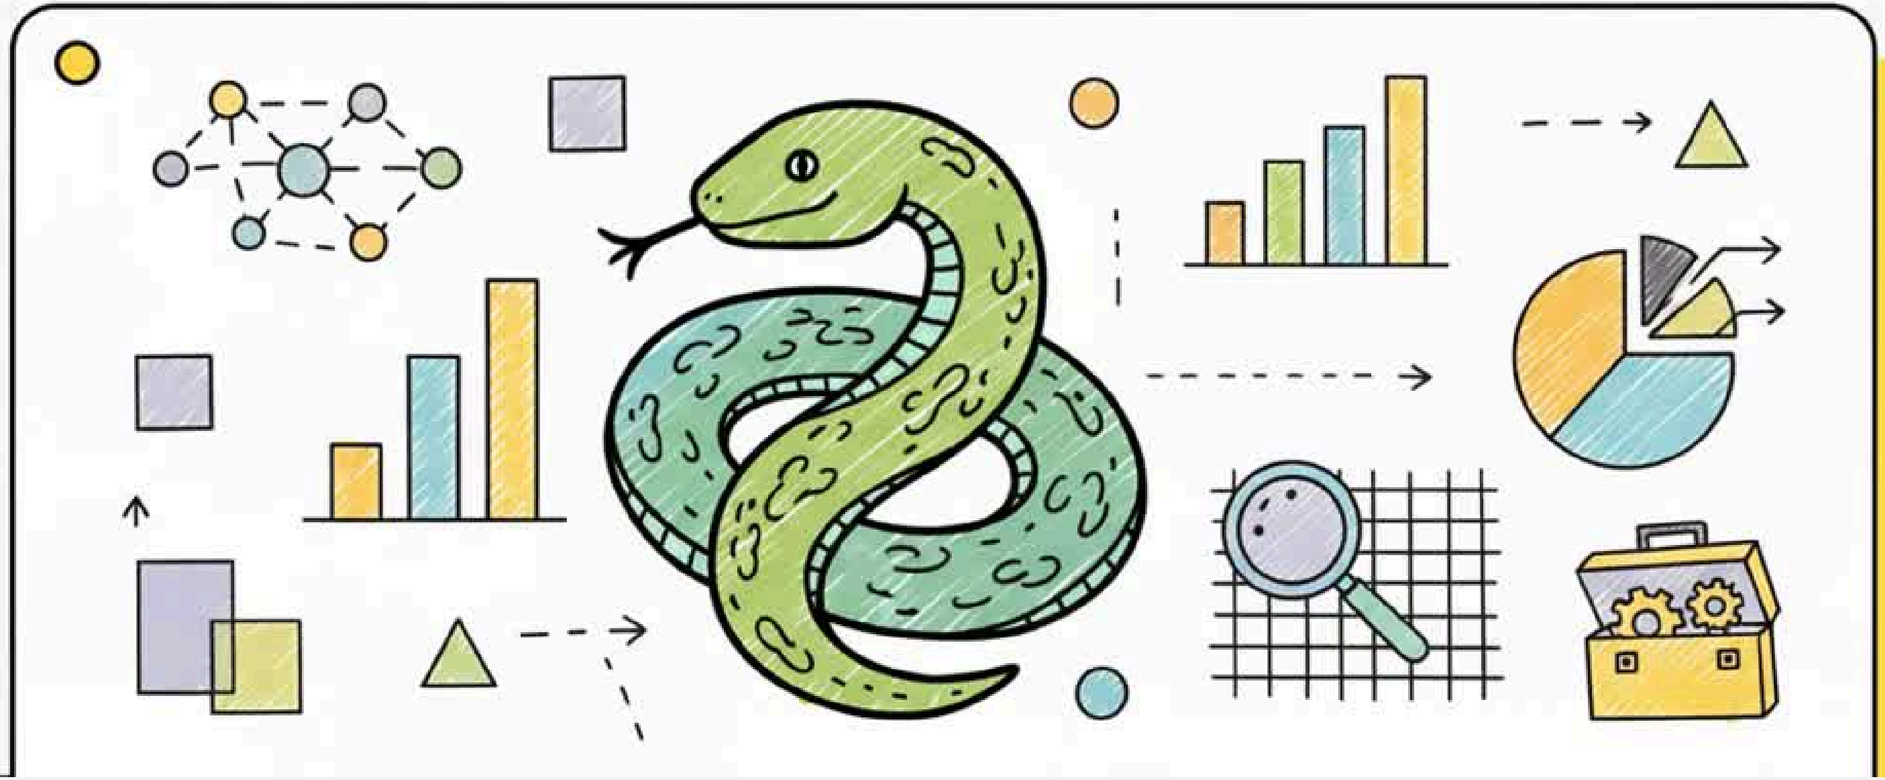

Data Visualisation

APPRENEZ L'IA,
SOYEZ ACTEUR DU
CHANGEMENT

Data Visualisation

- **C’est quoi la Data Visualisation, exactement ?**

La data visualisation, c’est l’art de transformer des données en images (graphes, courbes, cartes…) pour les comprendre plus vite.
Sans graphique, tu as juste un tableau Excel / DataFrame avec des chiffres.

Avec un graphique, ton cerveau voit immédiatement :

- la répartition (ex : la plupart des salaires sont entre 5k et 10k)
- les valeurs extrêmes (outliers)
- les groupes (ex : clients jeunes vs plus âgés)

Data Visualisation

- **C’est quoi la Data Visualisation, exactement ?**

Les graphiques sont utiles pour :

- voir si quelque chose augmente ou diminue dans le temps

Data Visualisation

- **C’est quoi la Data Visualisation, exactement ?**

Types de variables

- Numériques continues : taille, poids, prix
- Numériques discrètes : nombre d’enfants, nombre de commandes
- Catégorielles : genre, pays, type de produit
- Temporaires (dates) : jour, mois, année, horodatage

Data Visualisation

- **C’est quoi la Data Visualisation, exactement ?**

Les bons types de graphiques selon les variables :

- Numérique seule → histogramme, boxplot
- Numérique vs temps → courbe (line plot)
- Numérique vs catégorie → barplot, boxplot
- Numérique vs numérique → scatter plot

Data Visualisation

- Pour un dataset volumineux, qui contient plusieurs types de variables en même temps, comment allons-nous faire, Salma ?

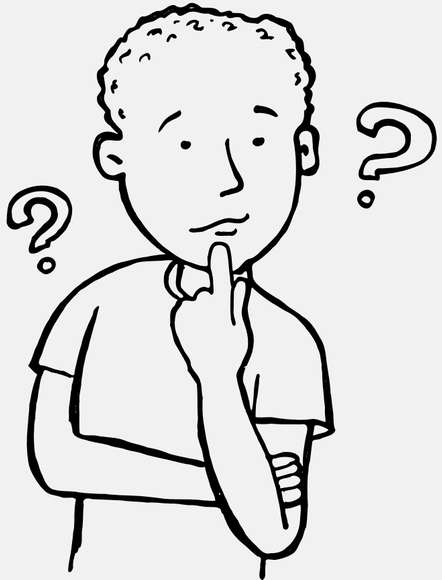

Data Visualisation

🧠 Méthode simple : pose-toi 2 questions

1️⃣ Combien de variables je veux visualiser ?

- 1 seule
- 2 variables
- 3 variables ou plus

2️⃣ Quels types sont ces variables ?

- numérique
- catégorielle
- temporelle

👉 *Une fois que tu connais ces 2 infos ⇒ le choix du graphe devient automatique.*

Data Visualisation

✅ 1 Variable

A) Variable numérique seule

👉 *Questions typiques* :

- Comment se répartissent les âges ?
- Quels sont les salaires les plus fréquents ?

📊 **Graphiques recommandés :**

Objectif	Graphique
Voir la distribution	**Histogramme**
Voir les extrêmes / médianes	**Boxplot**

Data Visualisation

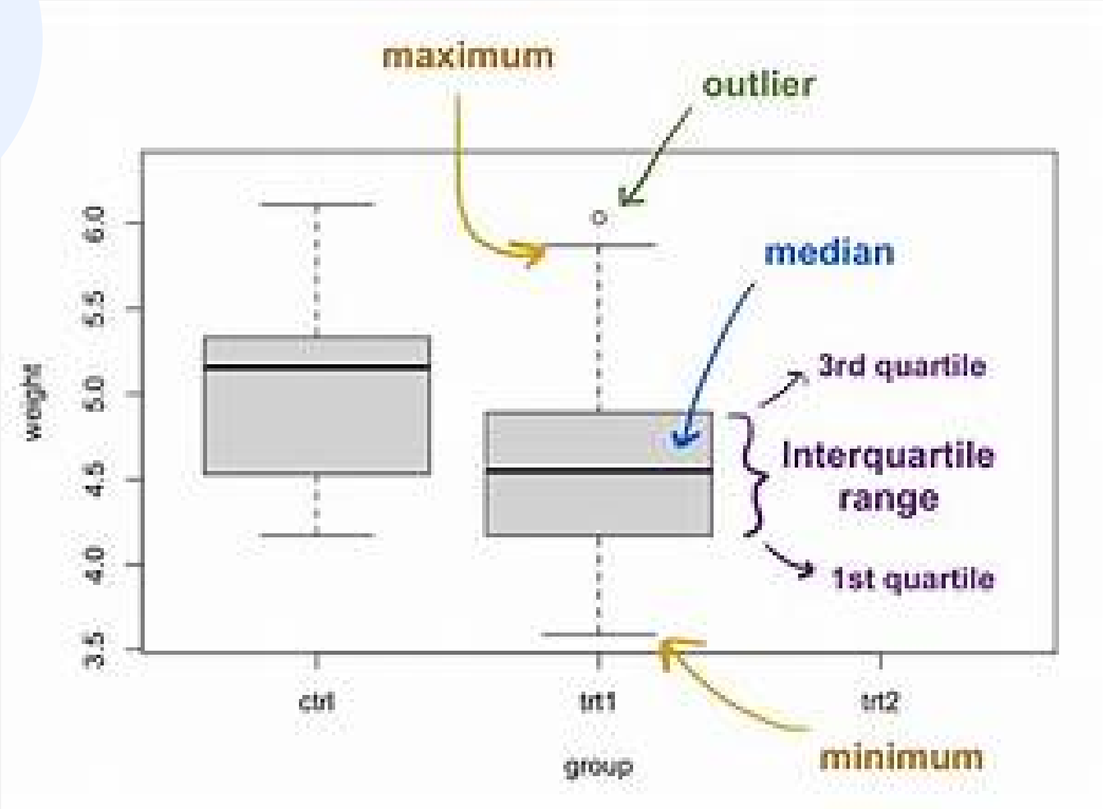

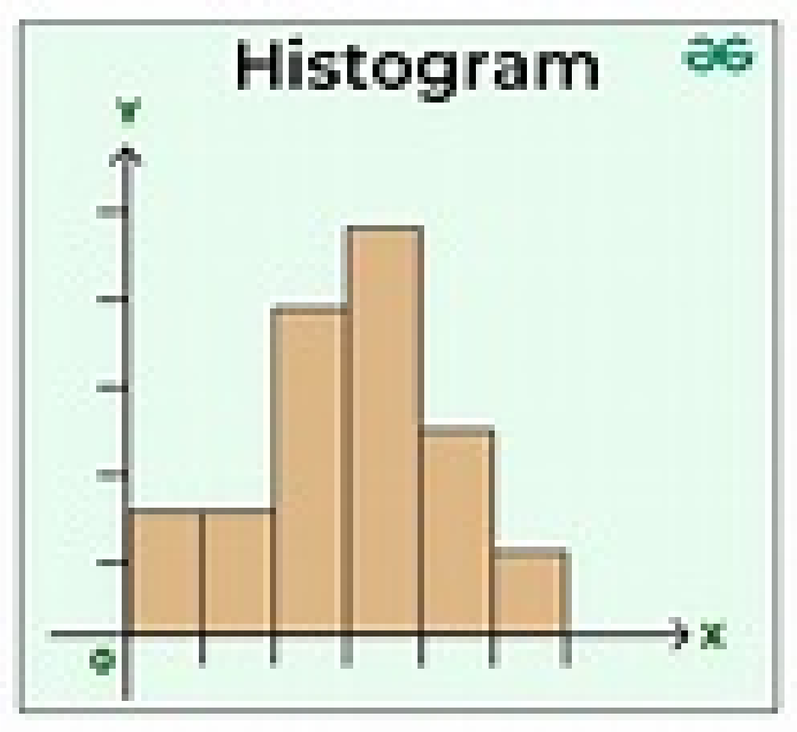

Data Visualisation

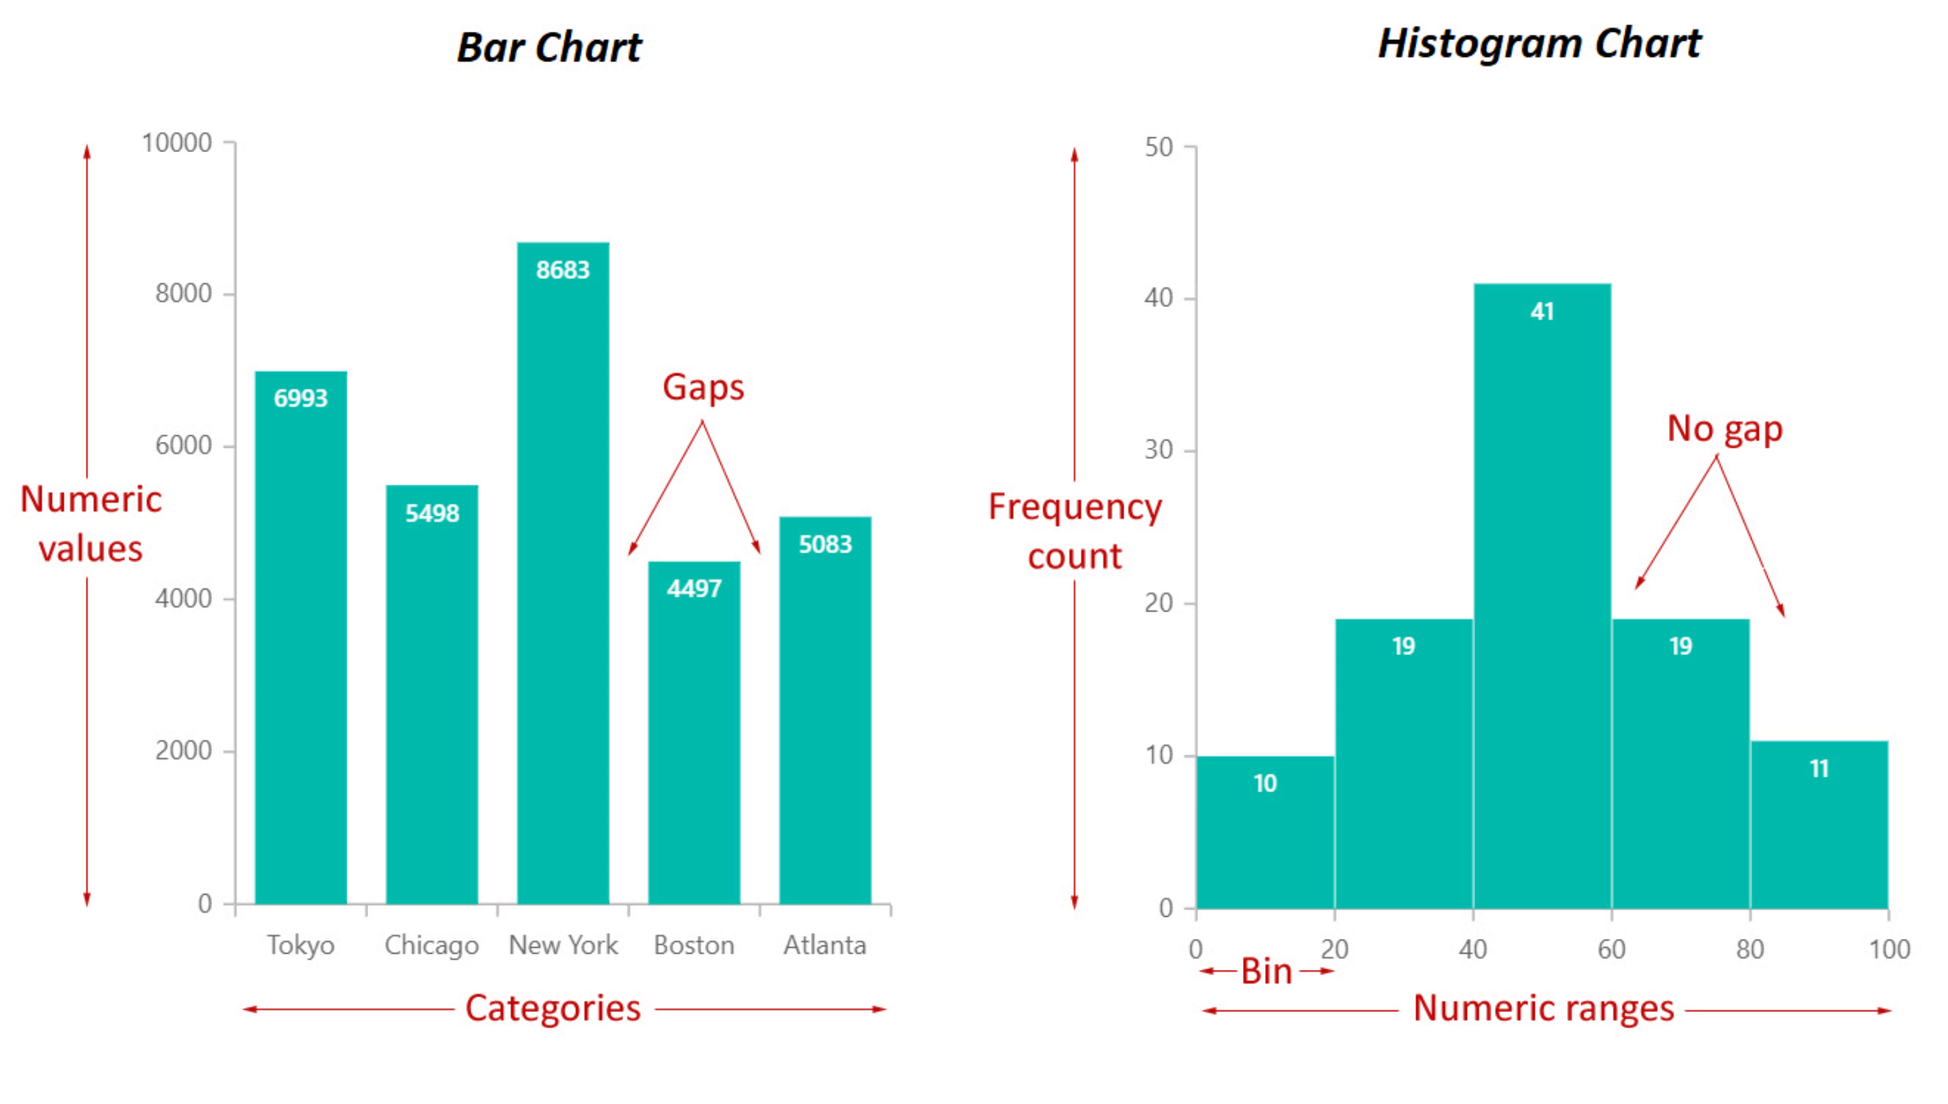

Data Visualisation

B) Variable catégorielle seule

👉 *Questions typiques* :

- Combien de clients par pays ?
- Combien de produits par catégorie ?

📊 **Graphiques :**

Objectif	Graphique
Voir les fréquences	**Bar plot simple**
Voir la proportion	**Pie chart (rarement conseillé)**

Data Visualisation

✅ 2 Variables

A) Numérique ➜ Numérique

👉 *"Est-ce que deux variables sont liées ?"*

📊 **Graphique idéal :**

- **Scatter plot (nuage de points)**

x	y
151	40
153	46
154	52
155	44
157	44
157	54
158	48
160	44
162	46
162	50

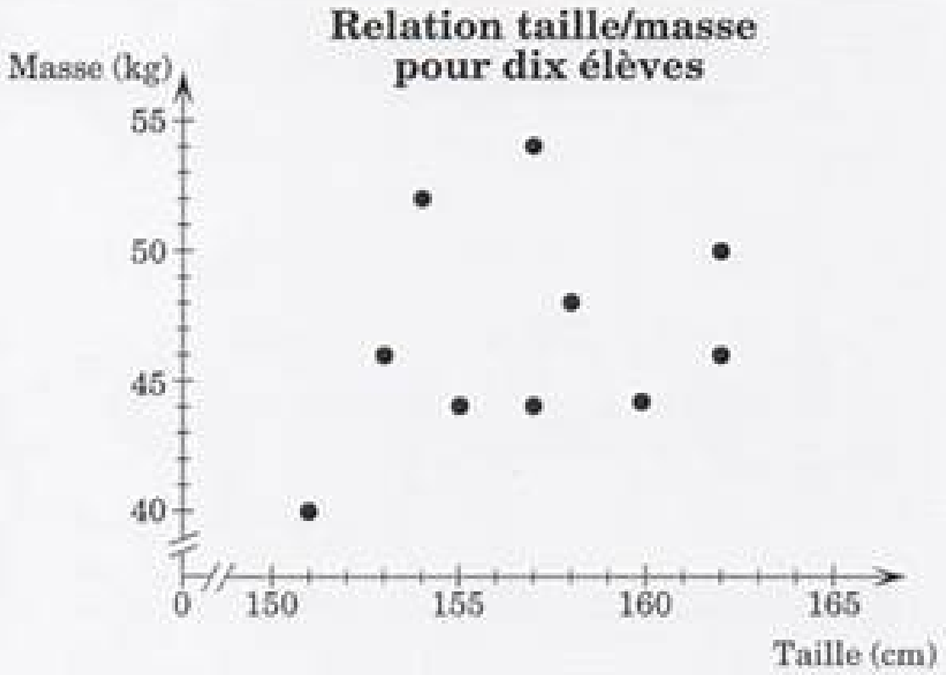

Data Visualisation

B) Numérique → Catégorielle

👉 *Exemples :*

- prix moyen par catégorie
- âge moyen par pays

📊 **Graphiques :**

Objectif	Graphique
Moyenne par catégorie	**Bar plot**
Répartition par catégorie	**Boxplot**

Data Visualisation

C) Numérique ➜ Temporel (dates)

👉 *"Comment évolue la valeur dans le temps ?"*

📊 **Graphique unique :**

- **Line plot (courbe)**

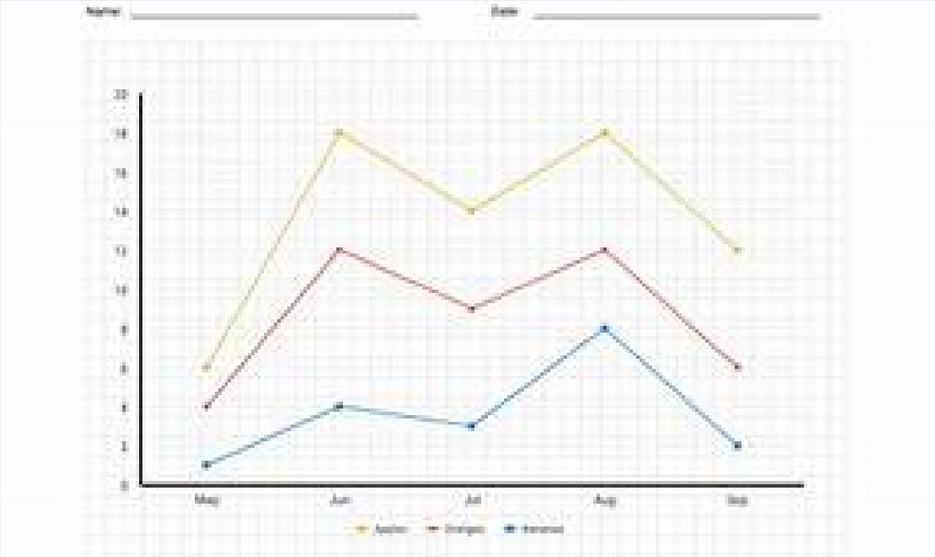

D) Catégorielle ➜ Catégorielle

👉 *Ex : Sexe vs Catégorie de produit*

📊 **Graphique :**

- **Heatmap de contingence**
- **Barplot empilé**

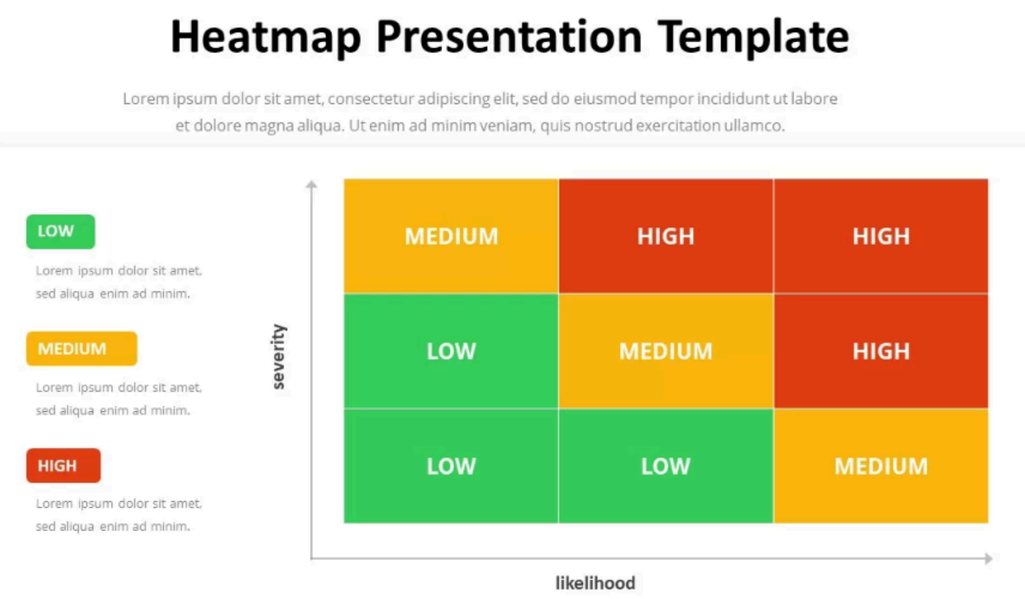

Data Visualisation

ASTUCE SUPRÊME

- **Numérique vs numérique → Scatter plot**
- **Numérique vs temps → Line plot**
- **Numérique vs catégorie → Barplot / Boxplot**
- **Numérique seul → Histogramme**

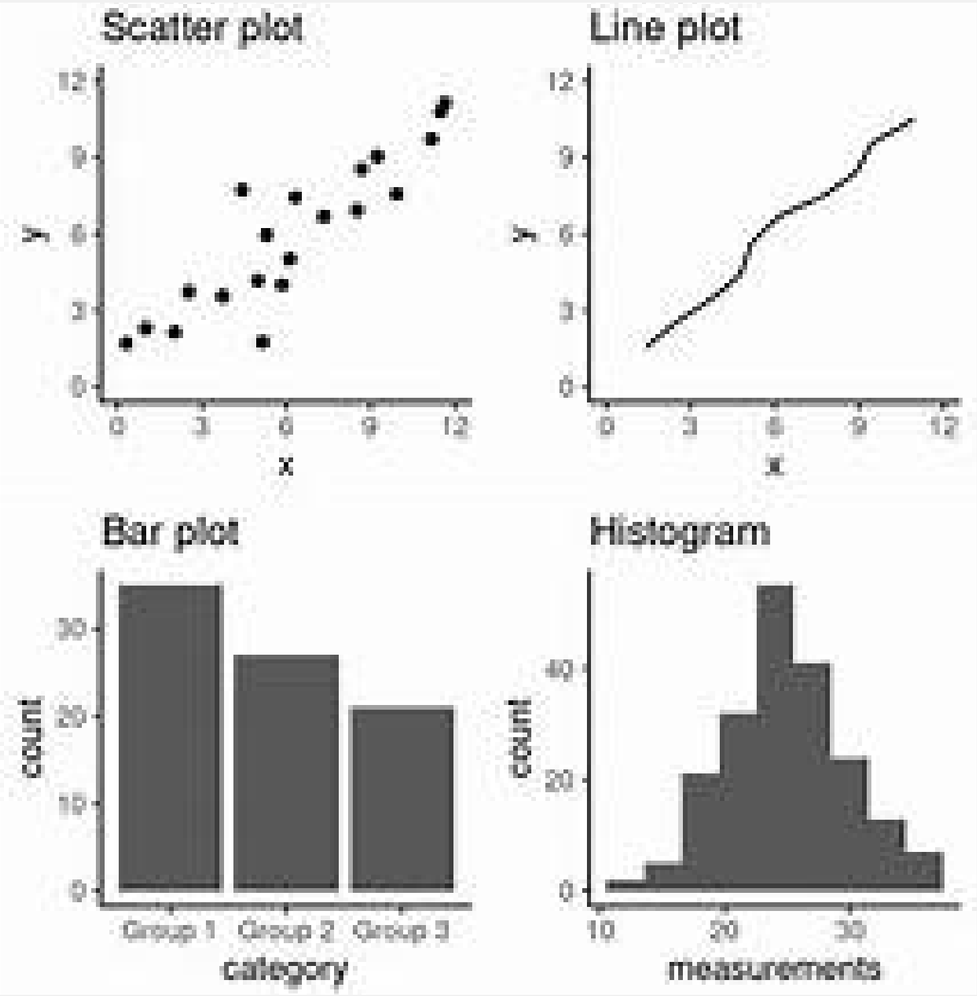

Data processing

APPRENEZ L'IA,
SOYEZ ACTEUR DU
CHANGEMENT

Data Processing = préparer les données

Pourquoi on fait du Data Processing ?

Le data processing (ou data preprocessing) est l'ensemble des étapes qui permettent de transformer des données brutes en données propres, exploitables

📌 Les données brutes sont souvent :

- incomplètes (valeurs manquantes)
- non normalisées (prix en € vs prix en $)
- difficiles à analyser (texte, dates, catégories)

📌 Sans traitement :

❌ les modèles se trompent

❌ les visualisations sont fausses

❌ les analyses sont biaisées

Data Processing = préparer les données

Avec un bon processing :

- ✓ **les données deviennent propres**
- ✓ **faciles à visualiser**
- ✓ **prêtes pour l'IA et le ML**
- ✓ **les résultats deviennent fiables**

Bibliothèque ?

Un outil prêt à l’emploi qui facilite ton travail.

Calcul numérique : **NumPy**

- **INSTALLATION :**

```
pip install numpy
```

- **IMPORTER NUMPY :**

```
import numpy as np
```

Calcul numérique : **NumPy**

- **CRÉATION D'UN TABLEAU NUMPY :**

```
a = np.array([1, 2, 3, 4, 5])
```

- **TABLEAU À PLUSIEURS DIMENSIONS :**

```
b = np.array([[1, 2, 3], [4, 5, 6]])
```

Application

Créer :

1. Un tableau 1D contenant :

   [10, 20, 30, 40, 50]

2. Une matrice 2D contenant :

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$

Calcul numérique : **NumPy**

- **INFORMATIONS SUR LES TABLES :**

```
print(a.shape)
print(b.shape)
print(a.ndim)
print(b.ndim)
print(b.size)
print(b.dtype)
```

Calcul numérique : **NumPy**

- **CRÉATION RAPIDE DES TABLES :**

```
np.zeros((2,3))        # tableau 2x3 rempli de 0
np.ones((3,2))         # tableau 3x2 rempli de 1
np.eye(3)              # matrice identité
np.arange(0,10,2)      # [0 2 4 6 8]
np.linspace(0,1,5)     # 5 valeurs entre 0 et 1
```

Calcul numérique : **NumPy**

- **ACCÈS SIMPLE :**

```
a = np.array([10,20,30,40,50])
print(a[0])
print(a[-1])
```

- **SLICING:**

```
print(a[1:4])   # [20 30 40]

a[:3]   # [10 20 30]   → du début jusqu'à l'indice 2
a[2:]   # [30 40 50]   → de l'indice 2 jusqu'à la fin
a[-2:]  # [40 50]      → les 2 derniers éléments
```

Calcul numérique : **NumPy**

- **FONCTIONS MATHÉMATIQUES UTILES :**

```
print(np.sum(a))
print(np.mean(a))
print(np.median(a))
print(np.std(a))
print(np.min(a))
print(np.max(a))
```

Calcul numérique : **NumPy**

- **SAUVEGARDE ET CHARGEMENT DE DONNÉES**

```
np.save('data.npy', a)
b = np.load('data.npy')
print(b)
```

Panel Data : **Pandas**

- **INSTALLATION :**

```
pip install pandas
```

- **IMPORTER PANDAS :**

```
import pandas as pd
```

Panel Data : **Pandas**

- **LIRE UN FICHIER :**

```
df = pd.read_csv('data.csv')
df = pd.read_excel('data.xlsx')
```

- **ÉCRIRE UN FICHIER :**

```
df.to_csv('data_export.csv', index=False)
df.to_excel('data_export.xlsx', index=False)
```

Panel Data : **Pandas**

- **EXPLORER LES DONNEES :**

```
df.head()
df.info()
df.describe()
df.shape
df.columns
```

- **SELECTIONNER UNE COLONNE :**

```
df['Nom']
df[['Nom','Age']]
```

- **SÉLECTIONNER UNE LIGNE OU UNE VALEUR**

```
df.iloc[0]
df.loc[0,'Nom']
```

Panel Data : **Pandas**

- **FILTRER LES LIGNES :**

```
df[df['Age'] > 22]                    # condition simple
df[df['Ville'] == 'Casa']             # filtrer par texte
df[(df['Age']>20)&(df['Ville']=='Tanger')]  # condition multiple
```

- **AJOUTER / SUPPRIMER UNE COLONNE :**

```
df['Pays'] = 'Maroc'                  # ajouter
df.drop('Pays', axis=1, inplace=True)   # supprimer
```

Panel Data : **Pandas**

- **GÉRER LES VALEURS MANQUANTES :**

```
df.dropna(inplace=True)
df.fillna(0, inplace=True)
```

- **TRIER LES DONNÉES :**

```
df.sort_values('Age', ascending=False)
```

Panel Data : **Pandas**

- **SUPPRIMER LES DOUBLONS :**

```
df.drop_duplicates(inplace=True)
```

- **CONVERSION NUMPY :**

```
df.to_numpy()
```

```
DataFrame Pandas :
    Nom  Age   Ville
0  Nada   21  Tanger
1   Ali   25    Casa
2  Sara   22   Rabat

Tableau NumPy :
[['Nada' 21 'Tanger']
 ['Ali' 25 'Casa']
 ['Sara' 22 'Rabat']]
```

Visualisation : **matplotlib**

- **INSTALLATION :**

```
pip install matplotlib
```

- **IMPORTER MATPLOTLIB :**

```
import matplotlib.pyplot as plt
```

- **EXEMPLE DE BASE :**

```
import matplotlib.pyplot as plt

x = [1, 2, 3, 4]
y = [2, 4, 6, 8]

plt.plot(x, y)
plt.title("Graphique simple")
plt.xlabel("Axe X")
plt.ylabel("Axe Y")
plt.show()
```

Type de graphique	Fonction	Description
Courbe	plt.plot(x, y)	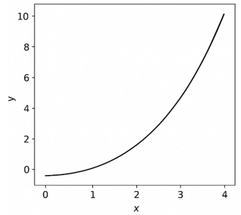
Barres verticales	plt.bar(x, y)	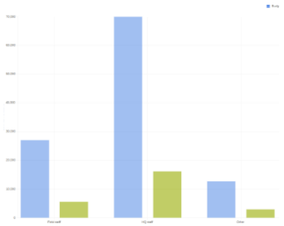
Histogramme	plt.hist(data)	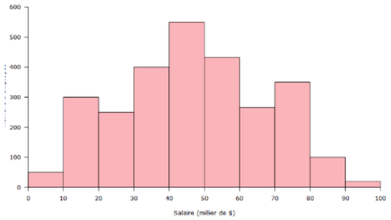
Nuage de points	plt.scatter(x, y)	
Camembert	plt.pie(valeurs, labels=...)	