Machine Learning

APPRENEZ L'IA,
SOYEZ ACTEUR DU
CHANGEMENT

Rappel :

Machine learning : Apprendre un modéle à partir des données

Types :

- **Supérviser :** Données étiquetées (input → output connu)

modéle : Regression linéaire, Régression logistique Descision Tree

Chat

Chien

- **Non supérviser :** Données sans étiquettes

modéle : K-Means, GMM...

Régression Linéare

Objectif : Predire une **valeur numérique continue** (prix, âge, salaire...) en traçant **la meilleur ligne droite** qui passe au milieu des données.

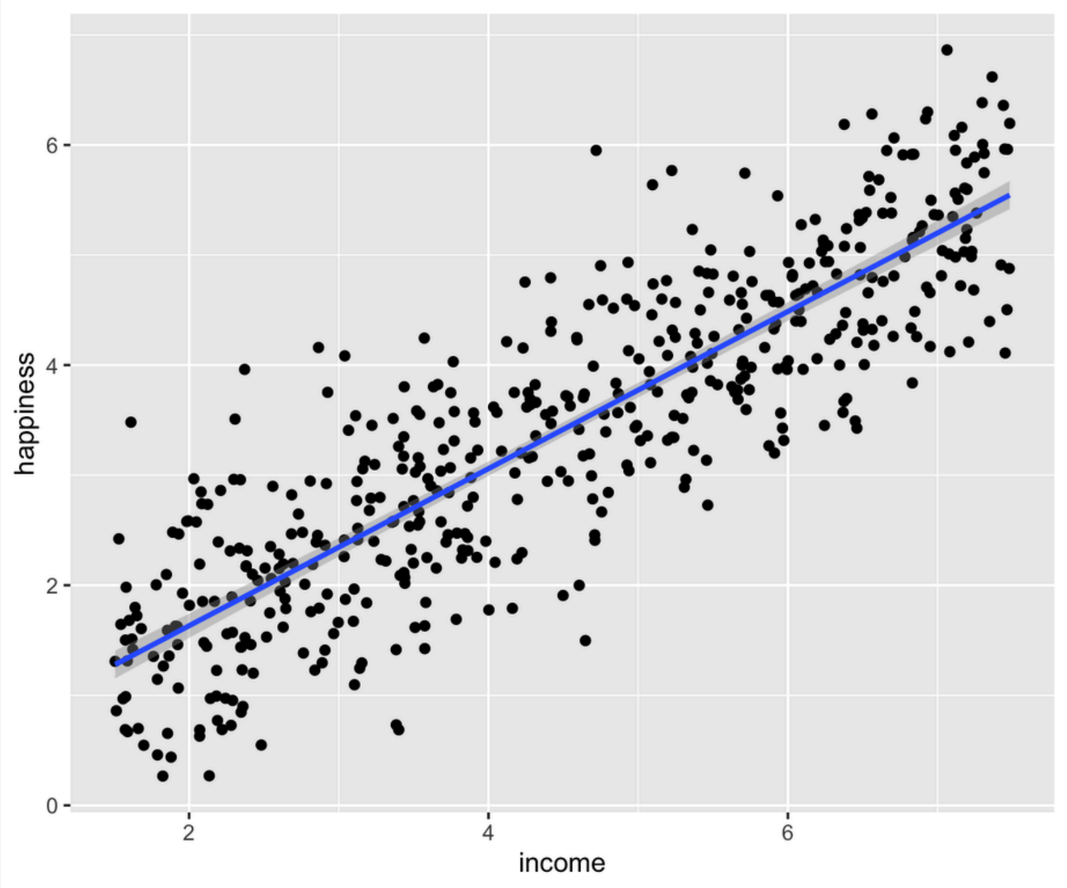

Régression Linéare

La forme de la ligne : **y = ax + b**

x : l'entrée
y : la prédiction
a : la pente
b : l'intersection (le ponit ou x = 0)

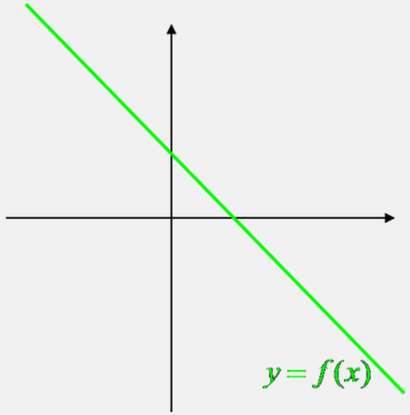

$f(x) = ax + b$ avec $a < 0$

Fonction affine décroissante

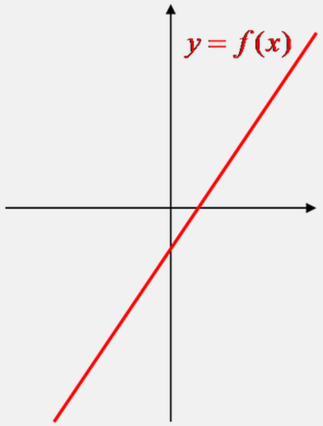

$f(x) = ax + b$ avec $a > 0$

Fonction affine croissante

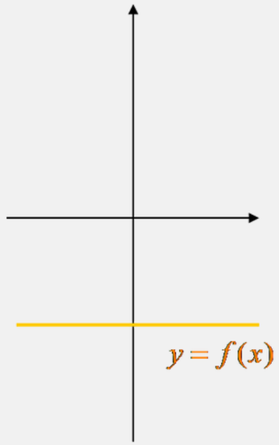

$f(x) = ax + b$ avec $a = 0$

Fonction affine constante

Comment Choisir la droite correspondante aux données ?

La droite optimale ?

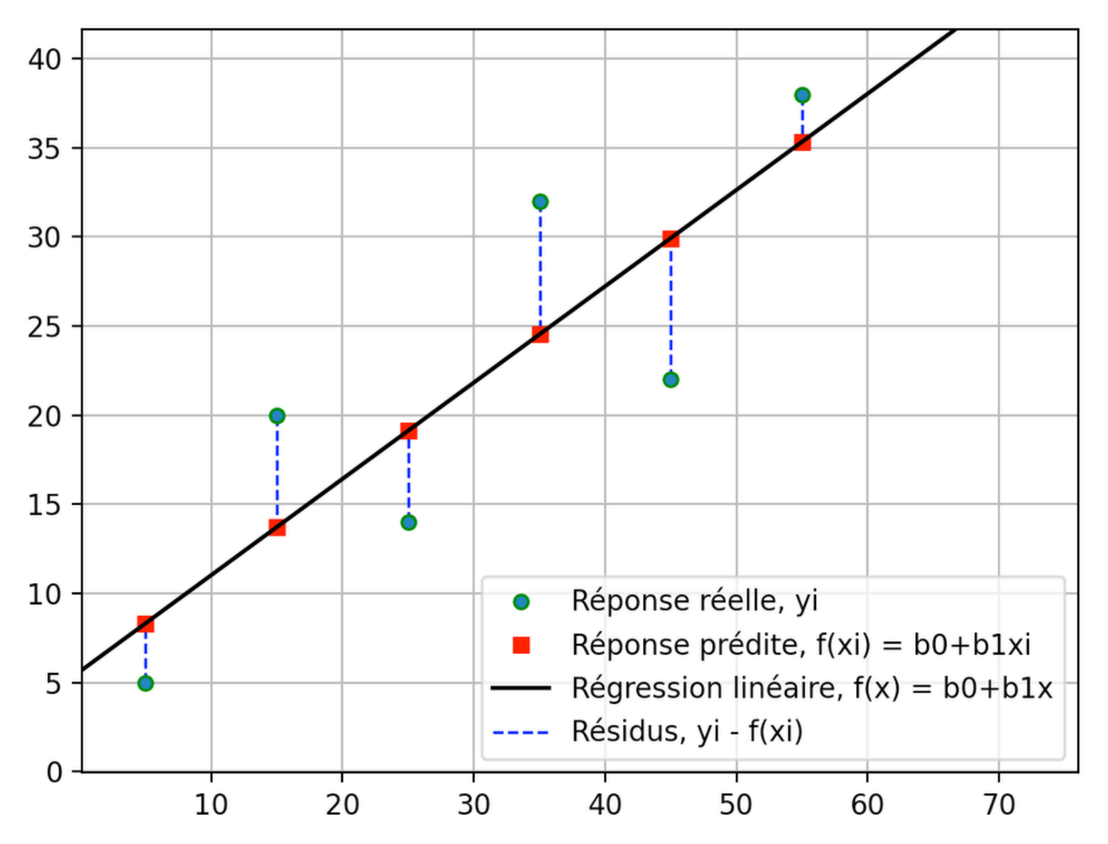

Erreur = y - ŷ

Erreur (résidus) : à quelle point le modèle se trompe

y : la valeur réel

ŷ : la prédiction du modèl

La droite optimale ?

Moyenne

Erreur

Carré

$$\mathrm{MSE} = \boxed{\frac{1}{n}} \sum_{i=1}^{n} \left(\boxed{Y_i - \hat{Y}_i}\right)^2$$

MSE : mean squared error, sert à mesurer à quelle point les prédictions du modèle sont loin des vraies valeurs

n : le nombre des points de données

La droite optimale ?

si MSE > 0 → le modéle est parfait

si MSE est grande : la droite ne correspond pas bien aux données

→ Alors le modéle veut **minimiser la MSE** (“la plus petite valeur gagne”)

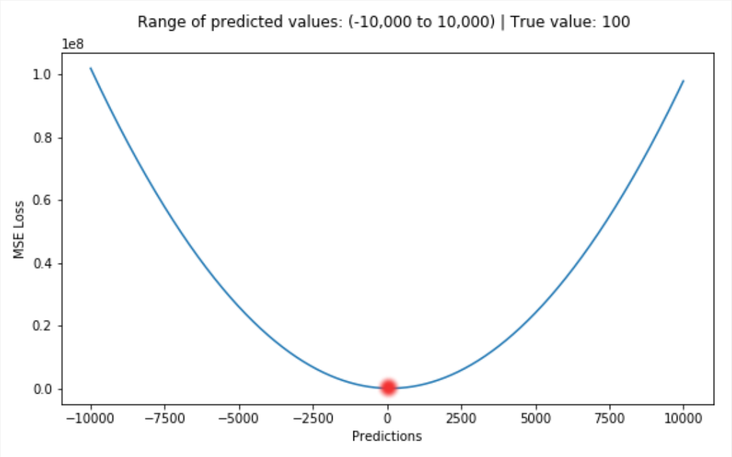

« Tout ce travail est réalisé automatiquement par le modèle. Vous, en tant que développeurs, n’aurez qu’à l’appeler. Mais comprendre la logique derrière le modèle reste essentiel pour l’utiliser correctement. »

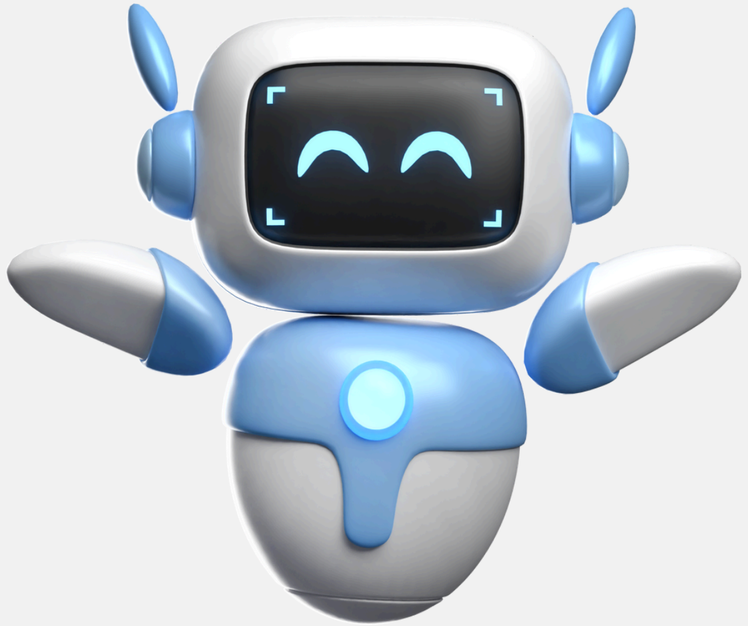

Machine Learning

APPRENEZ L'IA,
SOYEZ ACTEUR DU
CHANGEMENT

L’apprentissage supervisé

Régression

prédire une valeur numérique continue.
Par exemple : prédire le prix d’une maison, la température, ou un salaire.

Classification

prédire une catégorie.
Par exemple : SPAM ou NON-SPAM, Chat ou Chien, Malade ou Pas malade.
La régression logistique sert pour les problèmes où on doit choisir entre deux classes : 0 ou 1.

Rappel : Régression linéaire

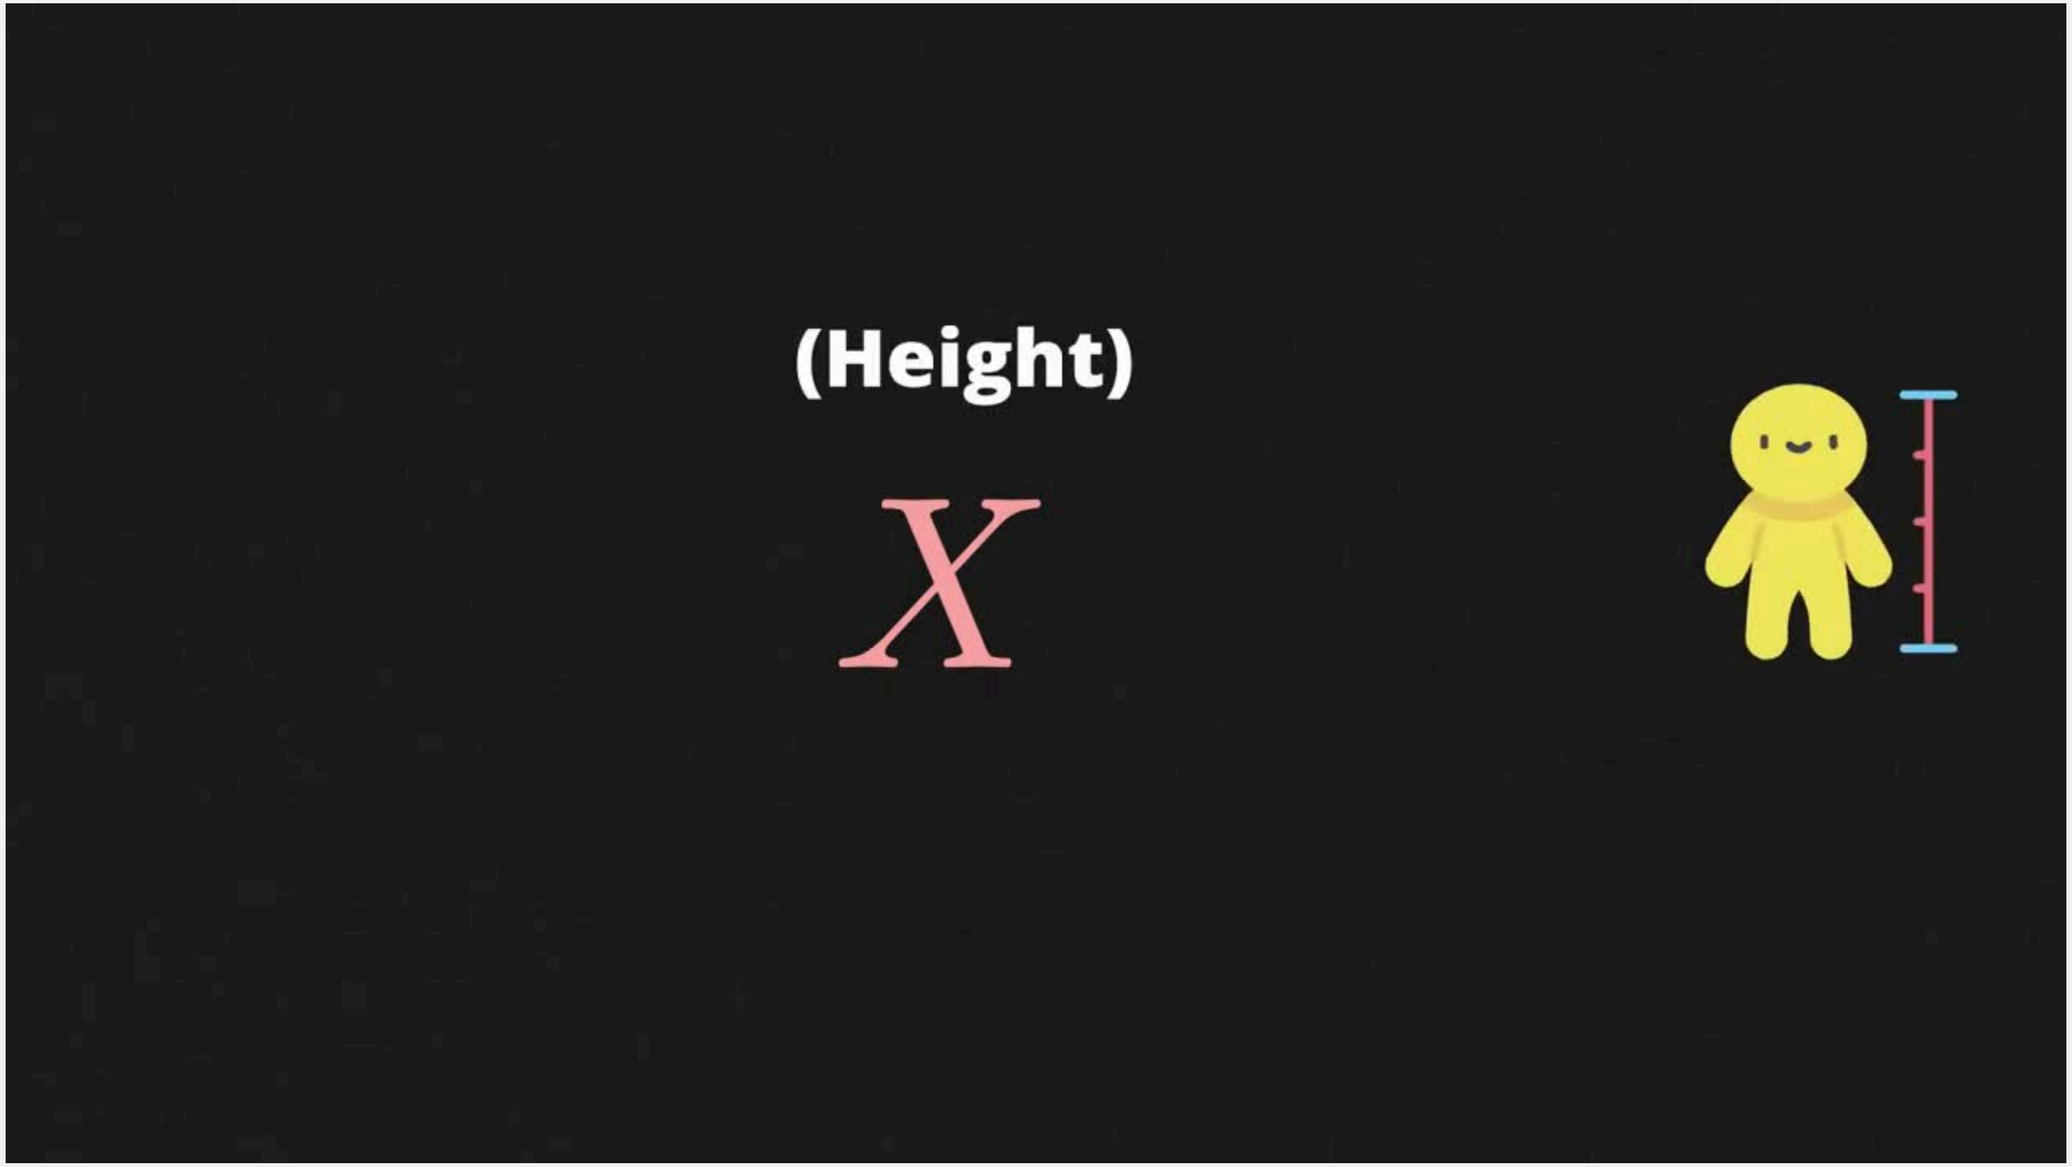

Régression vs classification

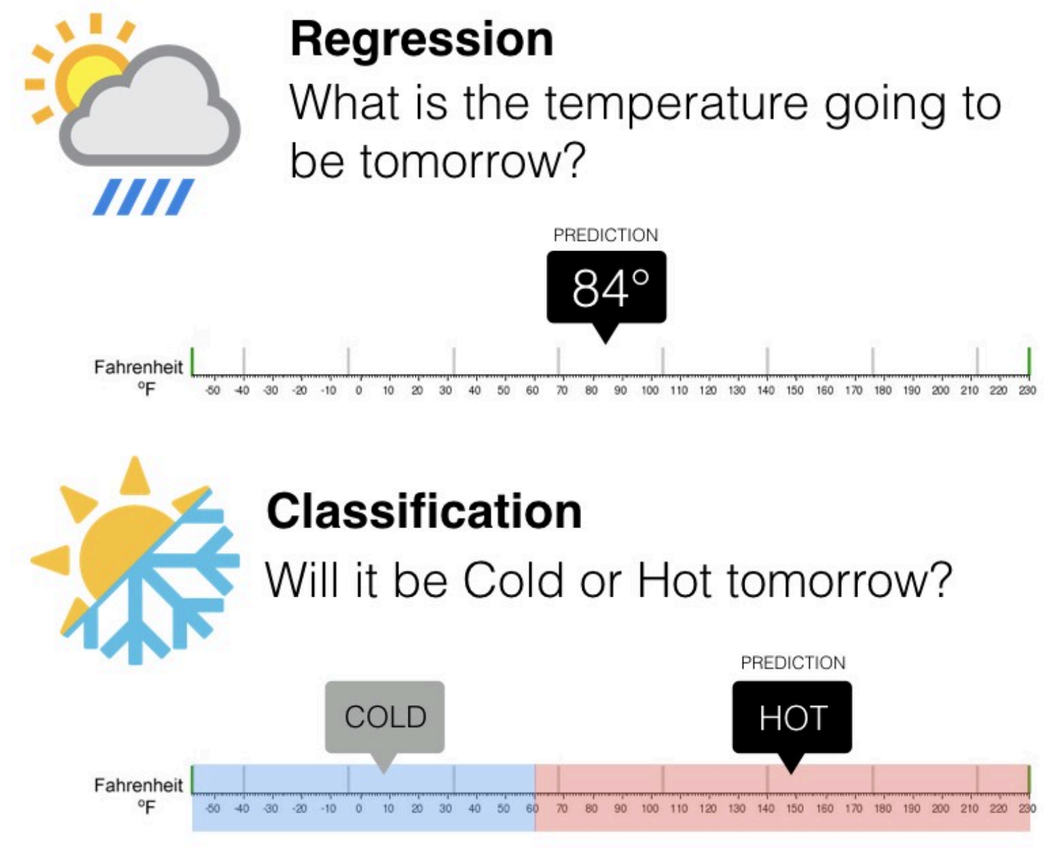

Limite de la regression linéaire

Premier problème :
La régression linéaire peut prédire n'importe quel nombre : −8, 0.3, 12…
Alors que dans la classification, nous voulons une probabilité, donc un nombre entre 0 et 1.

Deuxième problème :
La régression linéaire essaie d'ajuster une droite. Mais une droite ne sépare pas toujours bien les deux classes.

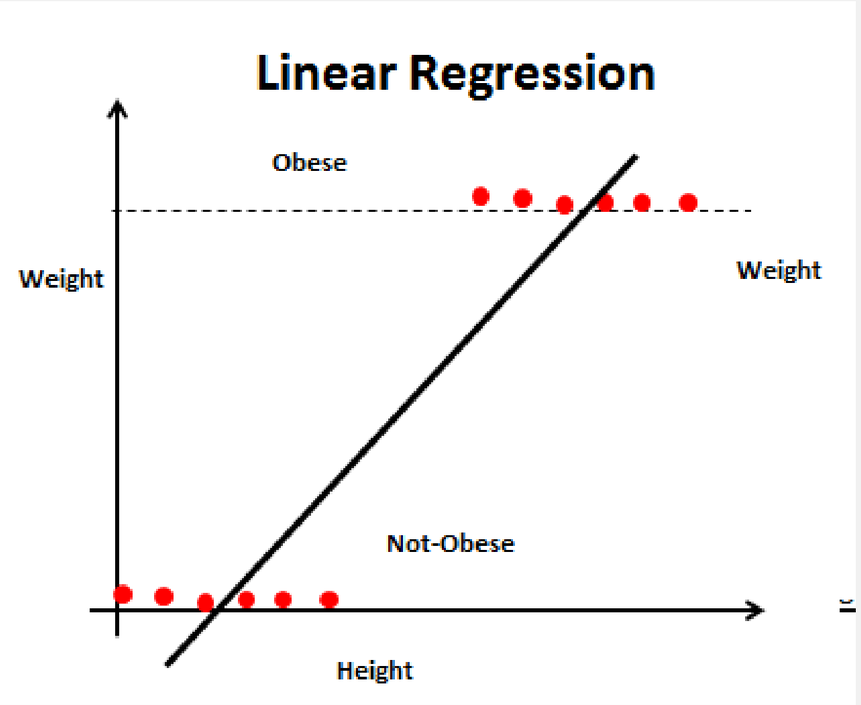

Régression Logistique

Objectif : prédire la probabilité qu'une variable appartienne à une catégorie (souvent binaire : 0 ou 1, oui ou non) en fonction d'un ensemble de variables.

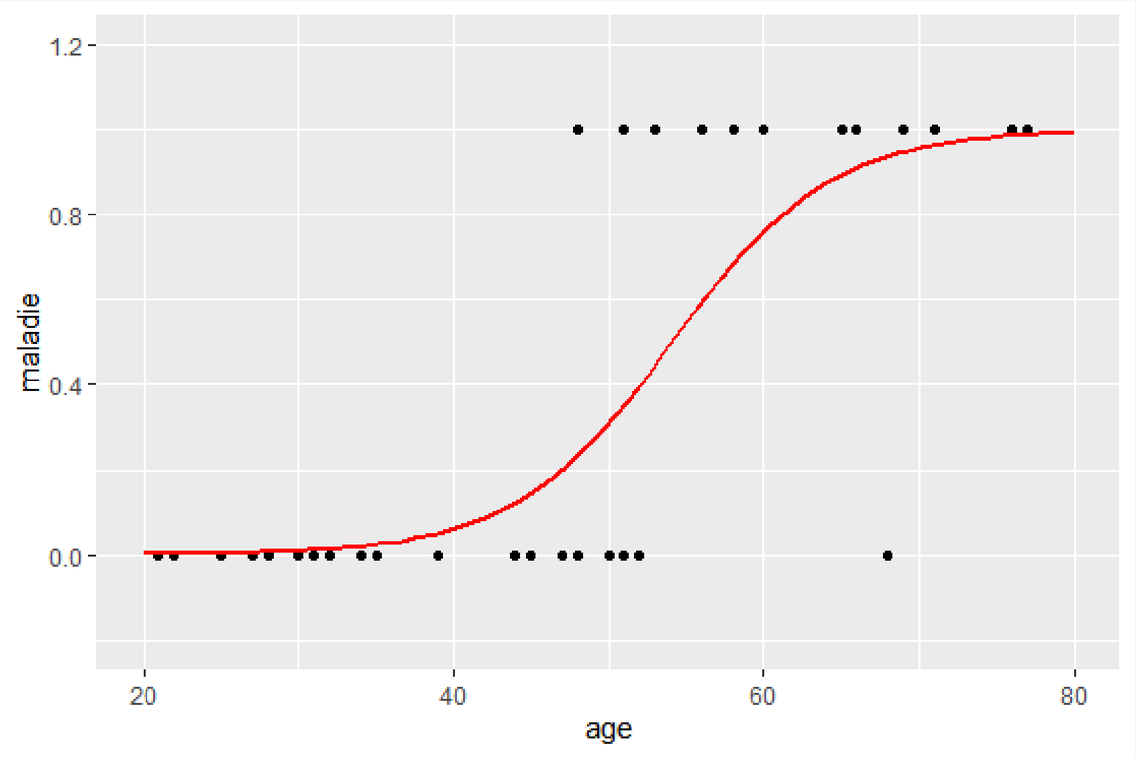

Régression Logistique

La fonction sigmoïde

Elle prend n'importe quel nombre, et elle renvoie toujours un résultat entre 0 et 1.

Donc elle se comporte comme une machine à fabriquer des probabilités.

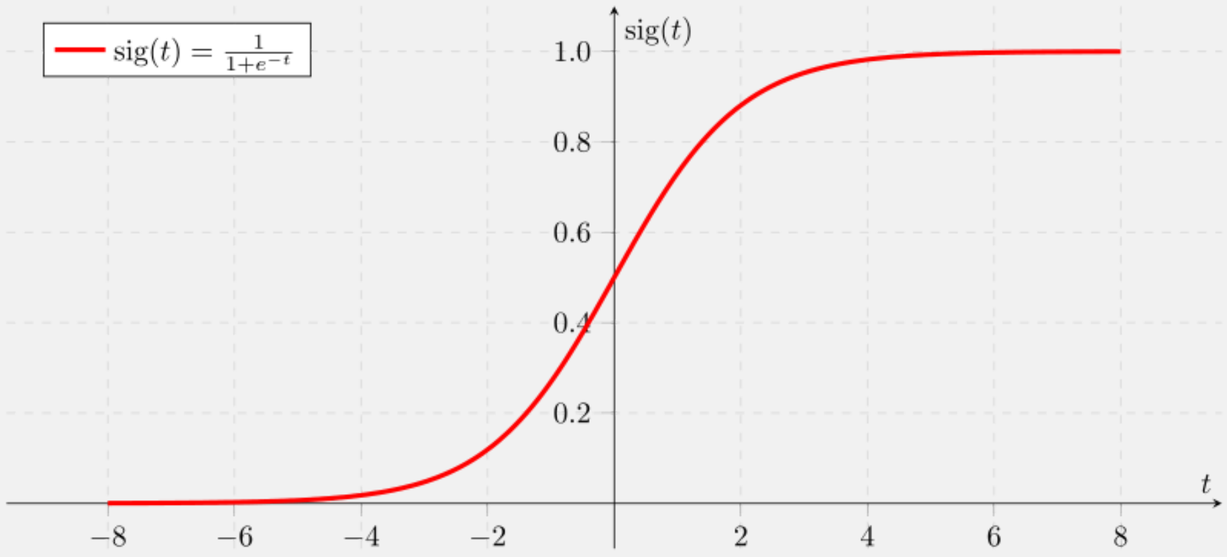

$$f(x) = \frac{1}{1+e^{-(x)}}$$

Régression Logistique

comment le modèle décide concrètement de la classe ?

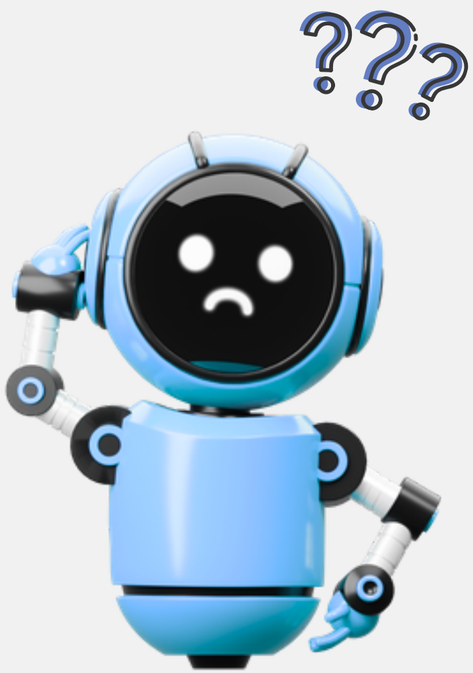

La decision boundary (frontière de décision)

Définition simple:

“La Decision Boundary est la ligne qui sépare la zone prédite comme classe 0 de la zone prédite comme classe 1.**”**

- **Une seule variable :**
La frontière est un point (ex : x = 5.2).

- **Deux variables :**
La frontière est une ligne droite.

- **Plusieurs variables :**
Une “surface” ou un “plan” invisible dans un espace 3D, 4D, etc.

La fonction de coût (Cost Function)

L'idée est très simple :

- Si le modèle fait une bonne prédiction (exemple : vrai = 1, prédiction = 0.95), le coût est faible.

- Si le modèle fait une mauvaise prédiction (exemple : vrai = 1, prédiction = 0.1), le coût est élevé.

Régression logistique

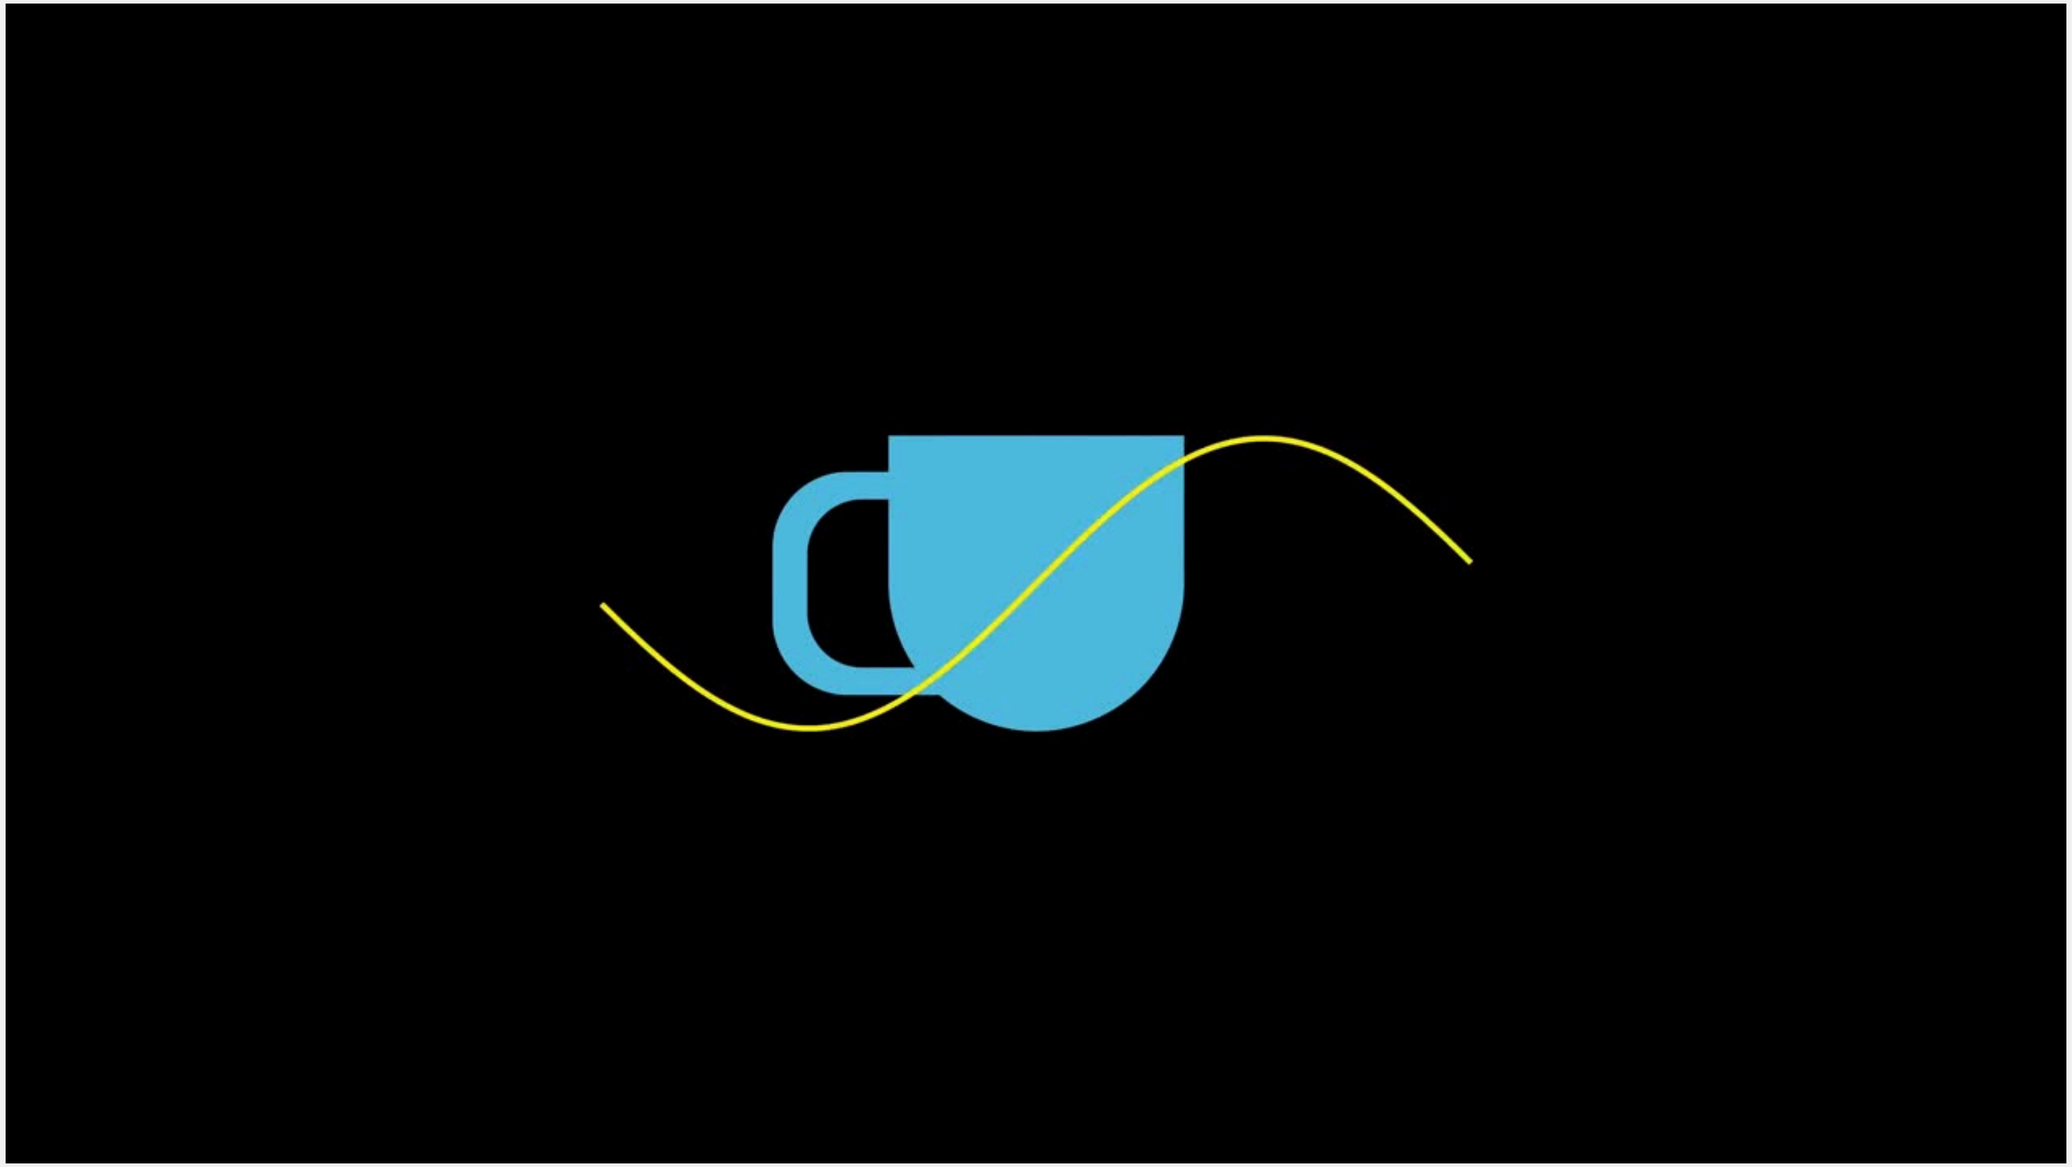

L’apprentissage non supervisé

Clustering

Le « **clustering** », est une technique d'apprentissage automatique non supervisé qui regroupe des ensembles de données non étiquetés en fonction de leur similarité

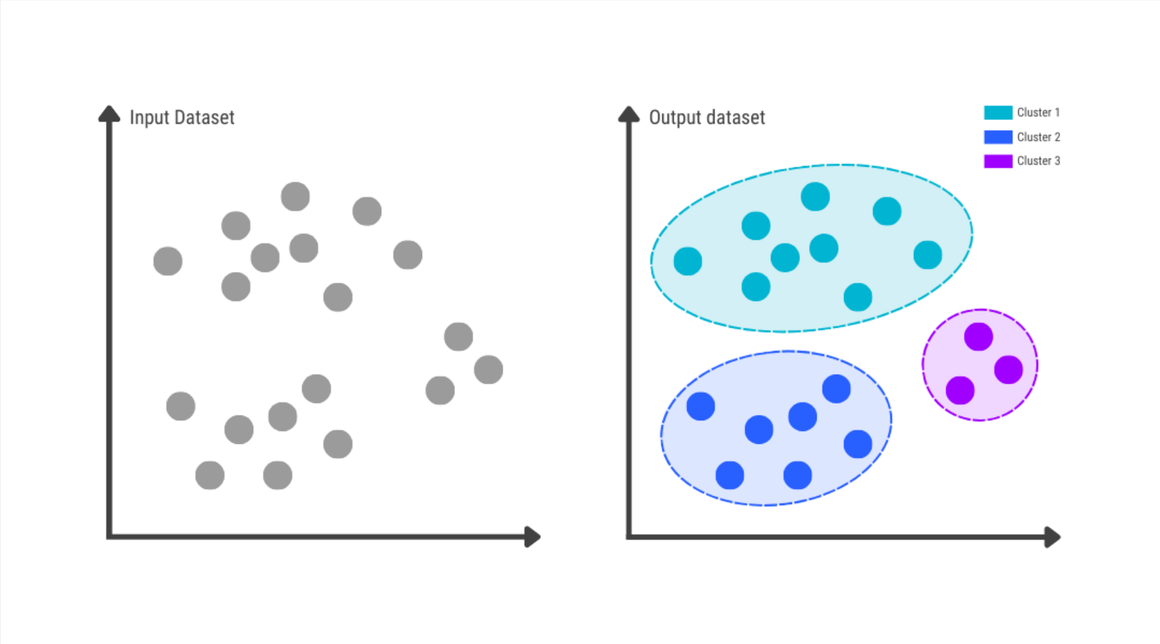

Clustering : K-means algorithme

Définition : regrouper les données en K groupes, de façon à ce que chaque point soit proche du centre de son groupe.

- K = nombre de clusters (groupes)
- Means = moyenne (car les centres = moyennes des points)

On place K centres, puis les points se rapprochent du centre le plus proche.

Clustering : K-means algorithme

Définition : regrouper les données en K groupes, de façon à ce que chaque point soit proche du centre de son groupe.

- K = nombre de clusters (groupes)
- Means = moyenne (car les centres = moyennes des points)

On place K centres, puis les points se rapprochent du centre le plus proche.
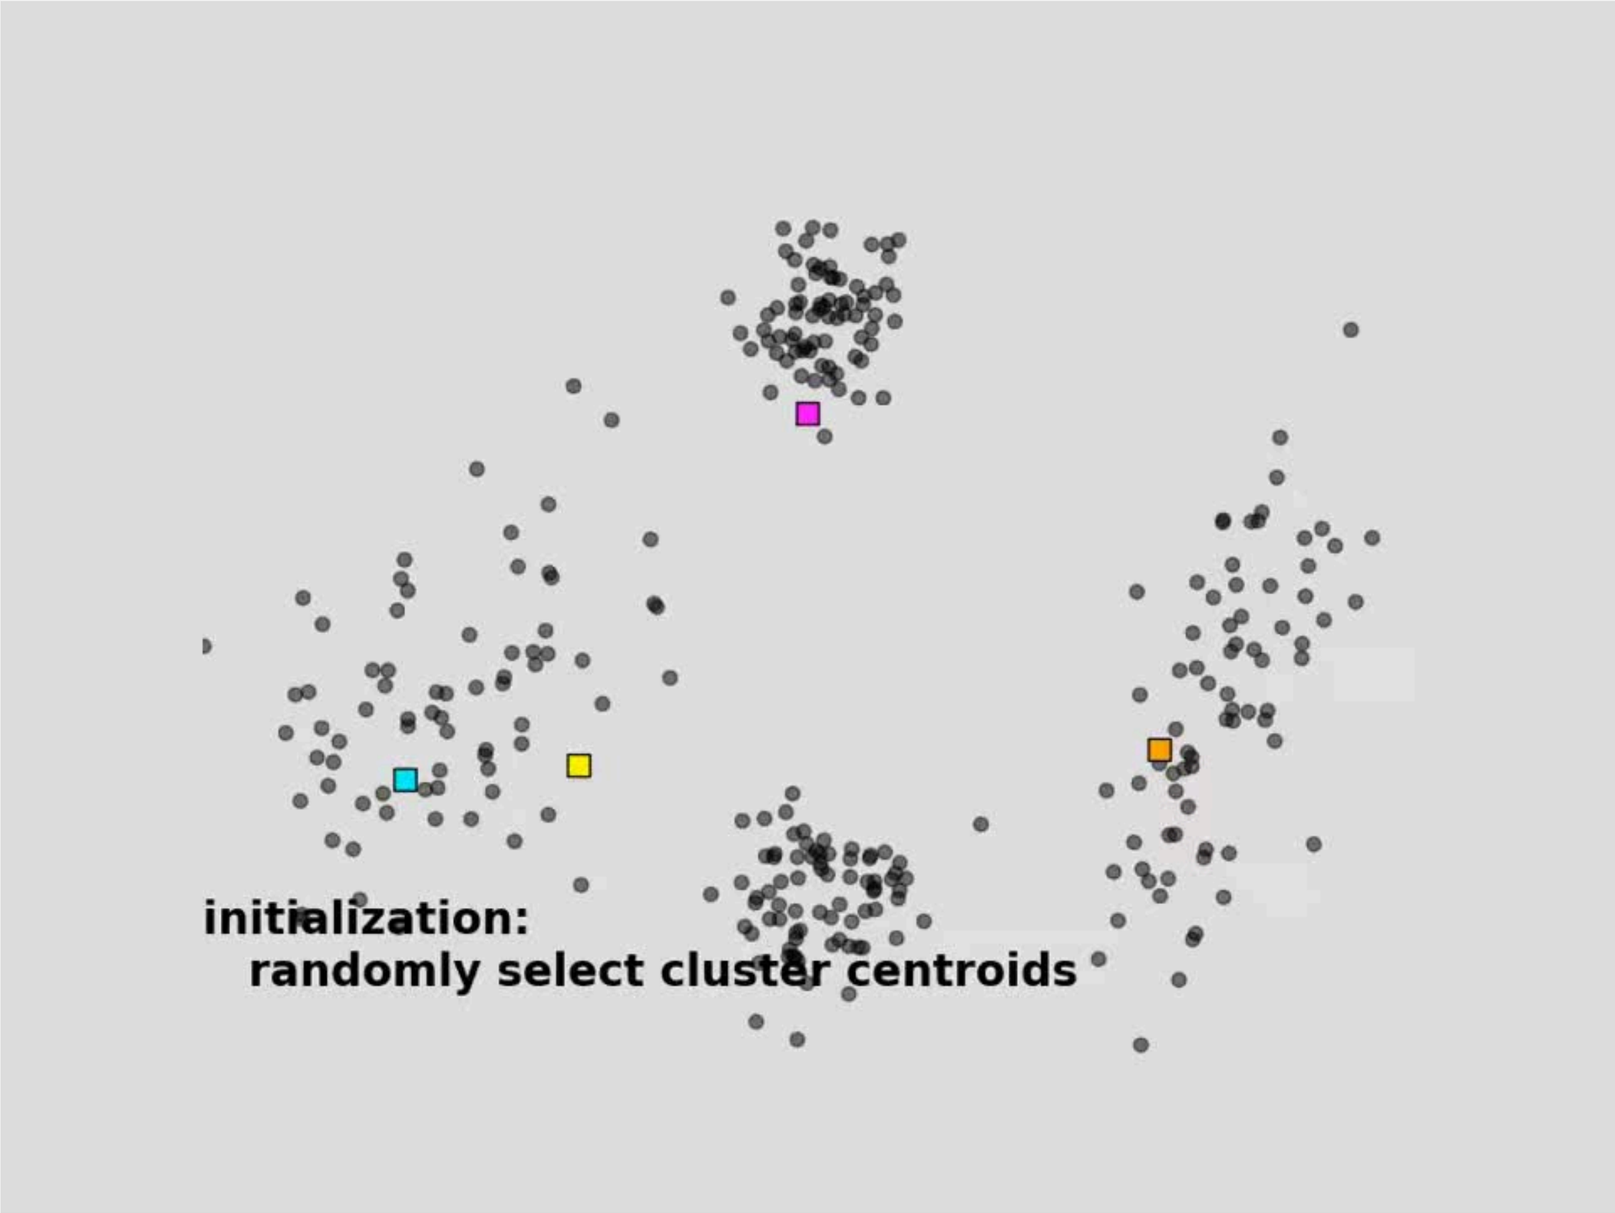
Clustering : K-means algorithme